Báo cáo tiến độ hệ thống sinh testcase tự động

Dự án Final Testcase Generator

Báo cáo gửi giảng viên hướng dẫn

Nội dung	Thông tin
Thời điểm chốt dữ liệu	17 giờ 07 phút ngày 12 tháng 10 năm 2026
Phạm vi	Code, dữ liệu và log hiện có trong Final_TestcaseGenerator
Quy tắc chọn run	Lấy kết quả hoàn tất gần nhất; loại toàn bộ batch bị dừng giữa chừng
Mục đích	Trình bày tiến độ, kết quả thực nghiệm, giới hạn và công việc tiếp theo

Kết luận chính

Pipeline đã tạo và khóa bộ test thành công cho 60 bài. Trong đó 59 bài có đủ TPR và TNR từ tập oracle độc lập. Macro TPR đạt 88.1%, macro TNR đạt 85.8%; 40/59 bài đạt đồng thời hai chỉ số từ 0,8 và 25/59 bài đạt đồng thời từ 0,9. Kết quả cho thấy pipeline đã vận hành được trên nhiều bài và nhiều ngôn ngữ, nhưng chất lượng chưa đồng đều giữa các bài.

Nội dung báo cáo

1. Phạm vi và phương pháp kiểm kê
2. Thuật ngữ và cách đọc kết quả
3. Kiến trúc codebase và luồng pipeline
4. Dữ liệu thực nghiệm
5. Giao thức đánh giá
6. Kết quả đã đạt được
7. Lỗi quan sát được và giới hạn
8. Phần việc đã hoàn thành và hướng tiếp theo
9. Phụ lục kết quả theo từng bài

Nguồn chính: README.md, Architect.md, Specs.md, testgen/, config/, data/problems/, output/**/report.json, output/batches/*/batch-report.json và log của từng bài.

1 Phạm vi và phương pháp kiểm kê

Báo cáo phản ánh trạng thái hiện có trên máy tại thời điểm chốt dữ liệu. Phạm vi chỉ gồm dự án Final_TestcaseGenerator. Không dùng dữ liệu bổ sung từ VPS, Kaggle hoặc kho khác và không chạy lại LLM, Docker, oracle hay bộ unit test trong lần lập báo cáo này. Các số liệu được đối chiếu từ mã nguồn, cấu hình, tệp dữ liệu, report JSON, khóa bộ test và log đã lưu.

1.1 Tiêu chí xác định kết quả hoàn tất

- Batch chỉ được đưa vào thống kê khi có finished_at và completed bằng total trong batch-report.json.
- Run thành công phải có report.json đúng schema pipeline và có test-suite.lock.json trong cùng thư mục.
- Kết quả theo bài lấy run thành công gần nhất trong tập hợp hợp lệ. Nếu lần thử mới nhất thất bại nhưng bài từng thành công trước đó, báo cáo giữ cả trạng thái thất bại mới nhất và số liệu thành công gần nhất.
- Bốn batch chưa hoàn tất bị loại toàn bộ, kể cả khi bên trong có một vài bài đã sinh report. Không có log nào chứa KeyboardInterrupt hoặc KeyboardInput trong 115 log batch đã kiểm tra.
- Report kiểm tra checker bổ sung được trình bày riêng vì không dùng schema của một run pipeline thông thường.

1.2 Quy mô bằng chứng

Hạng mục	Giá trị	Ý nghĩa
Batch hoàn tất	5	Được dùng để thống kê
Batch bị loại	4	Dừng giữa chừng hoặc thiếu finished_at
Lượt bài trong batch hoàn tất	81	64 thành công và 17 thất bại
Bài đã được thử	65	Lần thử gần nhất: 58 thành công, 7 thất bại
Bài từng có report hoàn chỉnh	60	Có khóa bộ test

Hạng mục	Giá trị	Ý nghĩa
Bài có đủ oracle TPR và TNR	59	Được dùng trong tổng hợp chất lượng

2 Thuật ngữ và cách đọc kết quả

Phần này giải thích các thuật ngữ được dùng xuyên suốt báo cáo. Các khái niệm được diễn giải theo cách pipeline đang triển khai, vì vậy người đọc có thể dùng trực tiếp để kiểm tra report JSON và log.

2.1 Đầu vào và đối tượng đánh giá

Problem. Một bài toán lập trình gồm mô tả, định dạng input, định dạng output, giới hạn và ví dụ chính thức. Mỗi problem có một mã như p02548 hoặc cf1004a.

Statement. Tệp statement.md chứa đề bài chuẩn hóa. Đây là nguồn thông tin chính để LLM phân tích miền dữ liệu, sinh code và đề xuất testcase.

Candidate solution. Chương trình ứng viên dùng để đánh giá bộ test. Pipeline sinh hai nhóm: candidate_ac được kỳ vọng đúng và candidate_wa được kỳ vọng sai.

Accepted và Wrong Answer. Accepted là nhãn cho chương trình được nguồn dữ liệu ghi nhận là đúng. Wrong Answer là nhãn cho chương trình từng cho kết quả sai. Đây là nhãn ban đầu, không phải chân lý tuyệt đối trong môi trường hiện tại.

Mutant. Một lời giải sai được tạo bằng cách đưa lỗi có chủ đích vào lời giải đúng hoặc sinh trực tiếp theo một lớp lỗi. Mutant chỉ được dùng để tính TNR sau khi vượt qua bước chứng nhận.

Witness. Một input cụ thể được kỳ vọng làm mutant sai. Witness phải hợp lệ, được validator chấp nhận, có expected output đáng tin cậy và tái hiện lỗi ổn định.

2.2 Thành phần xác định tính hợp lệ và đúng sai

Validator. Chương trình kiểm tra input có đúng grammar và ràng buộc của đề hay không. Validator chỉ trả lời input hợp lệ; nó không xác định expected output.

Checker. Thành phần so sánh output thực tế với expected output. Dự án có EXACT, TOKEN, CASE_INSENSITIVE_TOKEN, DECIMAL_EXACT, FLOAT và PYTHON_SCRIPT. Checker phải phù hợp với semantics của đề.

Reference solution. Candidate AC được dùng để tính output tham chiếu. Pipeline cần ít nhất hai reference chạy thành công và đồng ý theo checker trước khi chứng nhận một testcase.

Reference consensus. Sự đồng thuận của các reference về expected output. Đồng thuận làm giảm rủi ro dùng một lời giải duy nhất, nhưng nhiều reference vẫn có thể cùng sai.

Certified testcase. Testcase đã qua validator, không trùng, có expected output từ sample hoặc reference consensus, và đủ bằng chứng để đưa vào test suite.

Quarantine. Nơi lưu đề xuất bị từ chối do input sai, reference bất đồng, sample không khớp hoặc nguyên nhân khác. Test trong quarantine không được tính là testcase hợp lệ.

2.3 Các tập dùng trong thí nghiệm

Development candidates. Nhóm candidate được chấm trong các vòng sinh test. Kết quả của nhóm này có thể được đưa vào feedback cho vòng sau.

Holdout candidates. Nhóm mutant được giữ kín khỏi prompt sinh test. Nhóm này chỉ được chấm sau khi bộ test đã khóa, giúp kiểm tra khả năng tổng quát trong nội bộ pool LLM.

Oracle. Tập chương trình bên ngoài gồm Accepted và Wrong Answer từ CodeNet hoặc Codeforces. Oracle được chấm sau khi khóa test suite và không được đưa ngược vào prompt.

Test suite lock. Tệp test-suite.lock.json lưu hash và danh sách bộ test cuối. Pipeline kiểm tra khóa trước và sau khi chấm oracle để tránh thay đổi test theo kết quả ngoài.

2.4 Verdict

Verdict	Diễn giải	Cách dùng trong metric
PASS	Chương trình vượt toàn bộ testcase	Tính là giữ được một nhãn AC
WA	Output không được checker chấp nhận	Tính là bắt được một nhãn WA
RE	Chương trình lỗi khi chạy	Tính là bắt được một nhãn WA
TLE	Vượt giới hạn thời gian	Tính là bắt được nhãn WA, nhưng phản ánh cả hiệu năng
CE	Không biên dịch được	Không đưa vào mẫu số logic
INFRA	Lỗi Docker, SSH hoặc hạ tầng	Không đưa vào mẫu số; pipeline retry riêng

2.5 TPR TNR và coverage

TPR label based. Tỷ lệ chương trình mang nhãn Accepted hoặc candidate_ac vẫn PASS trên bộ test, sau khi loại CE và INFRA khỏi mẫu số. Chỉ số cao cho thấy bộ test ít loại nhầm chương trình đúng theo nhãn.

TNR label based. Tỷ lệ chương trình mang nhãn Wrong Answer hoặc candidate_wa bị WA, RE hoặc TLE, sau khi loại CE và INFRA. Chỉ số cao cho thấy bộ test bắt được nhiều chương trình sai theo nhãn.

TPR = số AC PASS / số AC đánh giá được TNR = số WA bị bắt / số WA đánh giá được

Macro average. Tính TPR hoặc TNR riêng cho từng bài rồi lấy trung bình. Mỗi bài có trọng số bằng nhau.

Micro average. Cộng số chương trình PASS, bị bắt và mẫu số của tất cả bài trước khi chia. Bài có nhiều chương trình đánh giá được sẽ có trọng số lớn hơn.

Coverage obligation. Một yêu cầu phủ được sinh từ test model, chẳng hạn biên nhỏ nhất, biên lớn nhất, quan hệ đặc biệt, trường hợp vô nghiệm hoặc stress. Coverage ratio là tỷ lệ obligation được gắn với ít nhất một testcase được chứng nhận.

Critical coverage. Tỷ lệ obligation ưu tiên critical đã được phủ. Cấu hình hiện tại yêu cầu 100 phần trăm để dừng sớm theo chất lượng.

Normal coverage. Tỷ lệ obligation ưu tiên normal đã được phủ. Cấu hình hiện tại đặt mục tiêu 90 phần trăm.

Label based và provisional. TPR và TNR đang đo mức phù hợp với nhãn lịch sử. Một AC bị fail có thể do testcase sai, checker sai, khác toolchain hoặc nhãn sai; một WA sống sót có thể do bộ test còn yếu. Vì vậy metric chưa phải chứng minh hình thức về độ đúng.

2.6 Vòng lặp và điều kiện dừng

Baseline iteration. Vòng đầu chỉ dùng statement và test model để sinh testcase phủ miền, chưa dùng source mutant hay kết quả oracle.

Adaptive iteration. Vòng sau nhắm vào mutant còn sống và khoảng trống coverage. Feedback chỉ chứa dữ liệu phát triển đã giới hạn, không chứa holdout hoặc oracle.

Top up. Lượt sinh bổ sung khi số testcase được chấp nhận thấp hơn quota do trùng, validator từ chối hoặc reference bất đồng.

All quality criteria met. Run dừng vì đã đủ số vòng và số test tối thiểu, đạt ngưỡng metric phát triển, đạt coverage và hết tiến triển cần thiết.

Iteration limit. Run đã dùng hết số vòng cấu hình mà chưa thỏa toàn bộ điều kiện dừng sớm. Run vẫn có thể có oracle metric tốt hoặc coverage cao; tên này không đồng nghĩa run hỏng.

3 Kiến trúc codebase và luồng pipeline

Codebase tách domain, bộ sinh, judge, checker, nguồn oracle và orchestration. main.py là composition root: đọc CLI và cấu hình, chọn backend rồi tạo Pipeline. testgen/pipeline.py điều phối vòng đời của một bài. Cấu trúc này cho phép thay LLM, judge, checker hoặc nguồn oracle mà không đổi toàn bộ luồng.

Thành phần	Vai trò hiện tại
main.py	CLI, batch runner, chọn LLM và judge, preflight hạ tầng
testgen/domain.py	Mô hình Solution, Case, Result và interface Judge, Generator, OracleSource
testgen/ollama.py	Sinh test model, AC, validator, mutant, testcase, repair và audit
testgen/claude.py và chatgpt.py	Backend LLM trực tiếp thay cho Ollama khi được chọn
testgen/fallback.py	Chuỗi fallback backend cho từng nhiệm vụ
testgen/pipeline.py	Chứng nhận reference và mutant, vòng sinh test, khóa suite và tính metric
testgen/checker.py và checkers	Registry và plugin so sánh output
testgen/docker_judge.py	Biên dịch và chạy submission trong Docker local
testgen/remote_judge.py	Chuyển công việc chấm sang KHOI qua SSH

Thành phần	Vai trò hiện tại
testgen/native_judge.py	Backend smoke test Linux có cờ xác nhận vì không cách ly filesystem và network
testgen/retrying_judge.py	Retry riêng cho INFRA, không retry verdict của code
testgen/codenet.py	Nạp oracle cache hoặc xuất nguồn từ kho CodeNet
testgen/coverage.py	Chuẩn hóa obligation và tính coverage
testgen/progress.py	Ghi tiến độ và latency.jsonl

3.1 Luồng xử lý một bài

1. Đọc statement, metadata, checker profile và cấu hình runtime.
2. Chạy preflight để chọn Docker local, remote judge hoặc native smoke test theo tham số.
3. Sinh test model gồm grammar, constraints, quan hệ, fault model và coverage obligation.
4. Sinh candidate AC, candidate WA và validator; lưu response và source để audit.
5. Biên dịch candidate, kiểm tra AC trên sample và chọn reference đủ điều kiện.
6. Chứng nhận mutant bằng sample, witness, validator, reference consensus và hai lần tái hiện lỗi.
7. Sinh testcase baseline, sửa input bị validator từ chối, loại trùng và chứng nhận expected output.
8. Chấm development candidates, cập nhật survivor và coverage rồi sinh vòng adaptive nếu cần.
9. Khóa test suite và chấm holdout nếu pool đủ lớn.
10. Tải hoặc đọc oracle cache, chấm bằng cùng test suite và ghi report.json.
11. Khi chạy batch, ghi log từng bài và batch-report.json; lỗi một bài không làm mất kết quả bài đã hoàn tất.

3.2 Cấu hình đang sử dụng

Nhóm	Giá trị chính
Ứng viên	3 candidate AC, 5 candidate WA, tối thiểu 3 mutant được chứng nhận
Sinh test	10 test được chấp nhận mỗi vòng, tối thiểu 2 vòng và 18 test, tối đa 2 vòng theo config hiện tại
Coverage	100% critical và 90% normal cho điều kiện dừng sớm
LLM mặc định	gemma4:31b-cloud, fallback nemotron-3-ultra:cloud rồi Claude theo chế độ fallback
Judge	auto, 8 worker chạy, 2 worker compile, batch remote 8 input
Sandbox	512 MiB RAM, 1 CPU, 64 process, run timeout 5 giây, compile timeout 90 giây

Nhóm	Giá trị chính
Cách ly	Không mạng, root filesystem chỉ đọc, cap drop, no new privileges, tmpfs 32 MiB

4 Dữ liệu thực nghiệm

Thư mục data/problems hiện có 72 bài: 40 mã CodeNet, 31 mã Codeforces và 1 bài thuộc nhóm khác. Tất cả 72 thư mục có statement.md; 71 có metadata.json; 42 có checker profile riêng và 64 có oracle manifest cục bộ.

Loại checker profile	Số bài	Ý nghĩa
TOKEN	22	So sánh token theo thứ tự, bỏ khác biệt whitespace
EXACT	17	So sánh nội dung sau chuẩn hóa newline cuối
PYTHON_SCRIPT	3	Dùng checker theo semantics riêng của bài
Không có profile riêng	30	Dùng default TOKEN và cần rà trước khi coi metric là verified

Hạng mục oracle	Số lượng
Oracle manifest	64
Source có hash riêng	2519
Nhãn Accepted	1264
Nhãn Wrong Answer	1255
Python	964
C++	925
C	352
Java	278

Mỗi manifest ghi source tương đối, dialect, nhãn, SHA 256 và thông tin nguồn. Tổng số Accepted và Wrong Answer gần cân bằng, giúp TPR và TNR không bị chênh mạnh chỉ vì quy mô hai lớp. Tuy nhiên từng run thường dùng giới hạn 20 chương trình mỗi nhãn.

4.1 Kiểm tra độc lập checker của nhóm CodeNet bổ sung

Artifact output/codenet-additional20-validation/report.json ghi nhận 26 chương trình được chạy trên 116 cặp chương trình và testcase, bao phủ 20 bài. Số chương trình Accepted thất bại là 0. Phạm vi này dùng sample chính thức và probe viết tay cho special checker; đây không phải rejudge toàn bộ 800 source.

5 Giao thức đánh giá

Hai lớp đánh giá được giữ tách biệt. Lớp phát triển dùng candidate do LLM sinh để dẫn dắt vòng adaptive. Lớp bên ngoài dùng oracle chỉ sau khi test suite đã khóa. Report lưu verdict từng source để có thể kiểm tra trường hợp metric thấp thay vì chỉ nhìn một tỷ lệ tổng.

Lớp	Thời điểm chấm	Có vào feedback	Mục đích
Development	Sau từng vòng	Có	Diệt mutant đã biết và tìm coverage gap
Holdout	Sau suite lock	Không	Kiểm tra tổng quát trên mutant LLM được giữ kín
Oracle	Sau suite lock	Không	Đánh giá ngoài bằng source lịch sử độc lập

Các kết quả trình bày ở phần sau ưu tiên oracle metric. CE và INFRA bị loại khỏi mẫu số; TLE được tính là bắt được WA nhưng cần đọc cùng verdict nếu muốn tách lỗi hiệu năng khỏi lỗi logic. Macro và micro đều được báo để tránh kết luận dựa trên một cách gộp duy nhất.

6 Kết quả đã đạt được

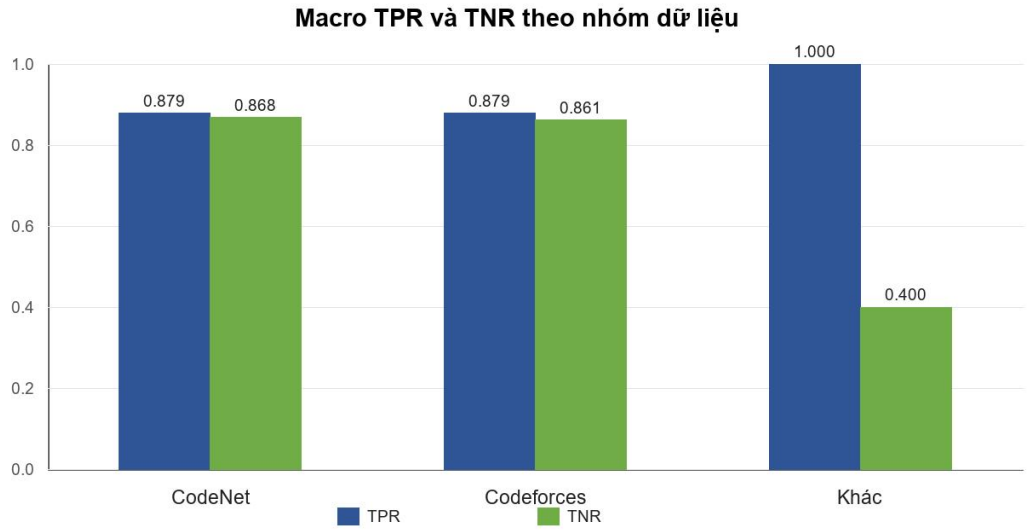
6.1 Tổng quan định lượng

Chỉ số	Kết quả	Cách hiểu
Bài có report hoàn chỉnh	60	Có test suite lock
Testcase được chứng nhận	1144	Trung bình 19,07 test mỗi bài
Coverage đạt 100%	48/60	Theo obligation trong test model
Dừng vì đủ chất lượng	27/60	Thỏa toàn bộ điều kiện dừng sớm
Dừng do hết vòng	33/60	Có report nhưng còn ít nhất một điều kiện chưa đạt
Macro TPR oracle	88.1%	Trên 59 bài đo đủ
Macro TNR oracle	85.8%	Trên 59 bài đo đủ

Chỉ số	Kết quả	Cách hiểu
Micro TPR oracle	87.6%	981/1120 AC PASS
Micro TNR oracle	86.8%	968/1115 WA bị bắt
Cả TPR và TNR từ 0,8	40/59	Ngưỡng theo báo cáo batch hiện có
Cả TPR và TNR từ 0,9	25/59	Nhóm kết quả mạnh
Có đánh giá holdout	5/60	Chỉ xuất hiện khi pool mutant đủ lớn

6.2 Kết quả theo nguồn dữ liệu

Nhóm	Run	Đo đủ	TPR TB	TNR TB	Cả hai từ 0,8	Coverage 100%
CodeNet	39	39	87.9%	86.8%	26/39	32/39
Codeforces	20	19	87.9%	86.1%	14/19	15/20
Khác	1	1	100.0%	40.0%	0/1	1/1

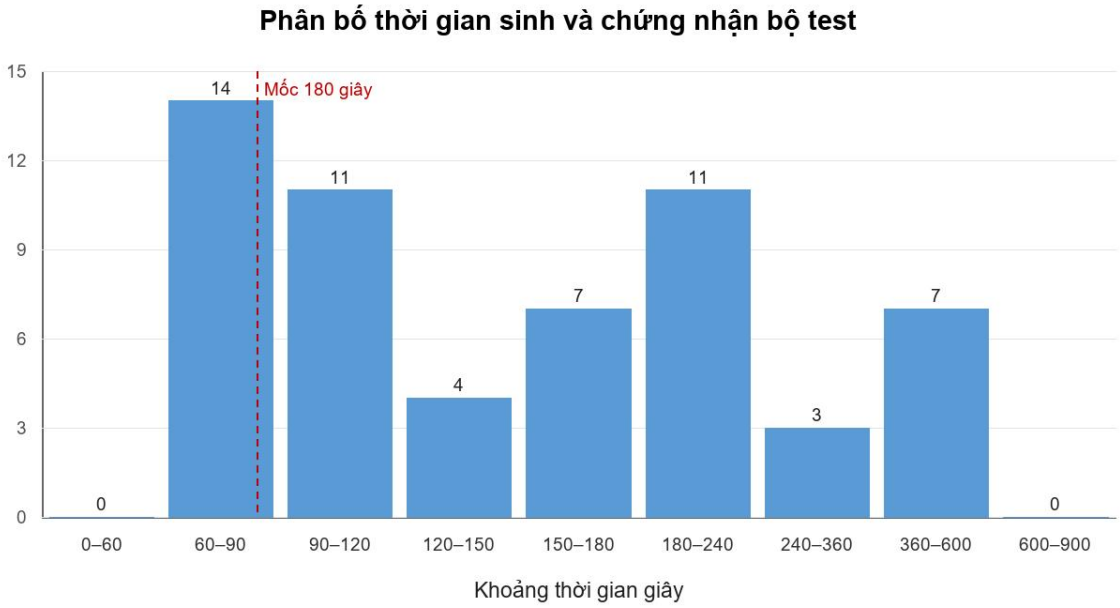


Hình 1 Macro TPR và TNR theo nhóm dữ liệu

CodeNet và Codeforces có macro TPR gần như bằng nhau. Macro TNR CodeNet nhỉnh hơn nhẹ. Nhóm Khác chỉ gồm một bài G1, nên không đủ để suy rộng; TNR thấp của bài này làm cột nhóm Khác giảm rõ rệt.

6.3 Thời gian sinh và chứng nhận bộ test

Có 57 run thành công gần nhất ghi generation_latency. Trung vị là 138,5 giây, trung bình là 178,6 giây và 36/57 run không vượt mốc 180 giây. Trung bình cao hơn trung vị vì một số run mất nhiều phút. generation_latency chỉ tính từ lúc bắt đầu đến khi có suite được chứng nhận và holdout; không bao gồm phần oracle bên ngoài.



Hình 2 Phân bố thời gian sinh và chứng nhận bộ test

Bài	Giây	Test	Coverage	Dừng
p02949	582,4	19	80.0%	Hết vòng
p02959	479,7	23	100.0%	Đủ chất lượng
p02709	474,7	22	100.0%	Hết vòng
p02678	460,9	14	87.5%	Hết vòng
p02623	377,2	21	88.9%	Hết vòng
p02839	360,6	17	100.0%	Hết vòng
p02661	360,3	21	100.0%	Đủ chất lượng
p03003	359,9	25	100.0%	Đủ chất lượng

6.4 Những bài có chỉ số cần ưu tiên cải thiện

Bài	TPR	TNR	Coverage	Test	Nhận xét
cf1949b	0.0%	100.0%	100.0%	19	Ưu tiên bảo toàn AC
cf2275d	100.0%	11.1%	0.0%	1	Ưu tiên bắt WA
cf1005a	100.0%	30.0%	0.0%	4	Ưu tiên bắt WA
p03044	100.0%	36.8%	0.0%	2	Ưu tiên bắt WA
cf1003c	40.0%	100.0%	100.0%	21	Ưu tiên bảo toàn AC
G1	100.0%	40.0%	100.0%	15	Ưu tiên bắt WA
p02586	45.0%	85.0%	90.9%	21	Ưu tiên bảo toàn AC
p02691	85.0%	50.0%	100.0%	22	Ưu tiên bắt WA
p02839	55.0%	80.0%	100.0%	17	Ưu tiên bảo toàn AC
p02949	94.7%	55.0%	80.0%	19	Ưu tiên bắt WA
p02623	95.0%	55.0%	88.9%	21	Ưu tiên bắt WA
p03003	75.0%	60.0%	100.0%	25	Ưu tiên bắt WA

TPR thấp cần được điều tra theo thứ tự checker, expected output, toolchain và nhãn Accepted trước khi kết luận testcase quá chặt. TNR thấp cho thấy bộ test chưa phân biệt được đủ chương trình Wrong Answer hoặc các nhãn WA không còn tái hiện trong môi trường hiện tại.

6.5 Trạng thái batch

Batch	Hoàn tất	OK	Lỗi	finished_at	Xử lý
20261010-160446	17/18	1	16	Không	Loại
20261010-162624	15/18	1	14	Không	Loại
20261011-235022	20/20	19	1	Có	Đưa vào
20261012-103819	20/20	20	0	Có	Đưa vào
20261012-134947	1/1	1	0	Có	Đưa vào
20261012-144702	20/20	10	10	Có	Đưa vào

Batch	Hoàn tất	OK	Lỗi	finished_at	Xử lý
20261012-160932	2/20	0	2	Không	Loại
20261012-161357	1/20	1	0	Không	Loại
20261012-162125	20/20	14	6	Có	Đưa vào

Bốn batch bị loại là 20261010-160446, 20261010-162624, 20261012-160932 và 20261012-161357. Việc loại theo batch bảo đảm báo cáo không trộn kết quả từ một quá trình bị dừng giữa chừng.

7 Lỗi quan sát được và giới hạn

7.1 Lỗi trong các batch hoàn tất

Nhóm lỗi	Số lượt	Ý nghĩa
Không sinh đủ AC hoặc validator	7	Dừng trước khi có đủ đầu vào tin cậy cho pipeline
Không đủ mutant WA được chứng nhận	6	Đề xuất WA không tái hiện ổn định hoặc không qua witness
Không đủ reference qua biên dịch và sample	3	Không thể thiết lập reference consensus an toàn
Remote judge không sẵn sàng	1	Lỗi SSH hoặc hạ tầng, không được gán thành verdict submission

Trong 81 lượt thuộc batch hoàn tất, có 17 lượt dừng trước metric. Pipeline không gán các lượt này TPR hoặc TNR bằng 0. Đây là lựa chọn đúng về mặt đo lường vì thiếu report không đồng nghĩa bộ test có chất lượng bằng 0.

7.2 Lần thử gần nhất bị lỗi

Bài	Batch	Thời gian	Nguyên nhân	Đã từng thành công
cf1003a	20261012-162125	75,3 giây	Không đủ mutant WA được chứng nhận	Có
cf1003b	20261012-162125	48,0 giây	Không đủ reference qua biên dịch và sample	Chưa
cf1004b	20261012-162125	27,2 giây	Không đủ reference qua biên dịch và sample	Chưa
cf1006b	20261012-162125	49,8 giây	Không đủ reference qua biên dịch và sample	Chưa
cf1008a	20261012-162125	36,1 giây	Không sinh đủ AC hoặc validator	Có
cf1009a	20261012-162125	68,8 giây	Không đủ mutant WA được chứng nhận	Chưa

Bài	Batch	Thời gian	Nguyên nhân	Đã từng thành công
p02732	20261011-235022	767,2 giây	Không đủ mutant WA được chứng nhận	Chưa

cf1003a và cf1008a từng có report thành công ở batch hoàn tất trước đó, nên phụ lục vẫn dùng số liệu thành công gần nhất của hai bài này. Năm bài chưa từng có report hoàn chỉnh trong phạm vi hợp lệ là cf1003b, cf1004b, cf1006b, cf1009a, p02732.

7.3 Giới hạn của kết quả hiện tại

- TPR và TNR dựa trên nhãn lịch sử. Các nhãn chưa được xác minh lại bằng một judge chính thức cùng toolchain và checker.
- Reference consensus làm giảm rủi ro nhưng không chứng minh expected output đúng nếu các reference cùng chứa một lỗi.
- Ba mươi ba trên sáu mươi run thành công gần nhất dừng vì hết vòng, cho thấy điều kiện dừng sớm chưa đạt đồng đều.
- Mười hai run chưa phủ 100 phần trăm obligation của test model; coverage cũng phụ thuộc chất lượng model phân tích đề.
- Chỉ năm run có holdout metric. Phần lớn đánh giá tổng quát dựa vào oracle ngoài, chưa có holdout LLM đồng đều cho mọi bài.
- Native judge dành cho smoke test và không có mức cách ly như Docker. Metric cuối không nên lấy từ backend này cho source không tin cậy.
- Báo cáo không chạy lại code hoặc test, nên không xác nhận trạng thái thực thi của Docker, SSH hoặc LLM tại thời điểm viết.
- Workspace không có Git metadata khả dụng; báo cáo không thể gắn kết quả với commit cụ thể.

8 Phần việc đã hoàn thành và hướng tiếp theo

8.1 Phần việc đã hoàn thành

- Hoàn thiện pipeline một lệnh cho một bài và batch tuần tự nhiều bài.
- Tách abstraction cho generator, judge, checker và oracle; runtime và sandbox đọc từ cấu hình.
- Bổ sung nhiều backend LLM, fallback theo nhiệm vụ và lưu raw response để audit.
- Chứng nhận reference, mutant và testcase trước khi tính metric.
- Tách development, holdout và oracle; khóa test suite trước đánh giá ngoài.
- Hỗ trợ Docker local, remote judge qua KHOI và native smoke test có cảnh báo.
- Tạo 72 bộ đề chuẩn hóa và 64 oracle bundle, tổng cộng 2.519 source có hash.
- Ghi report, iteration snapshot, execution log, latency và batch report để truy vết.
- Sinh report hoàn chỉnh cho 60 bài và đo đủ oracle TPR/TNR cho 59 bài.

8.2 Ưu tiên kỹ thuật tiếp theo

1. Điều tra các bài TPR thấp bằng cách đối chiếu từng AC fail với checker, expected output, runtime và nhãn gốc.
2. Tăng khả năng sinh validator và reference hợp lệ cho năm bài chưa từng hoàn tất; bổ sung prompt hoặc validator kiểm toán theo bài nếu cần.

3. Cải thiện TNR cho các bài có WA sống sót bằng fault model cụ thể hơn và testcase nhắm survivor, sau đó đánh giá lại trên oracle khóa kín.
4. Mở rộng holdout để có chỉ số tổng quát nội bộ trên nhiều bài hơn, đồng thời giữ nguyên ranh giới không đưa holdout vào feedback.
5. Phân tích các run vượt 180 giây theo latency component để xác định phần LLM, chứng nhận mutant hay judge chiếm thời gian.
6. Gắn mỗi đợt thực nghiệm với commit hoặc snapshot code để bảo đảm tái lập kết quả.
7. Khi chuẩn bị số liệu cho luận văn, xác minh lại nhãn ngoại lệ và tách WA logic, RE và TLE trong bảng kết quả cuối.

9 Kết luận tiến độ

Dự án đã vượt qua giai đoạn chứng minh ý tưởng: pipeline hiện có thể phân tích đề, sinh và chứng nhận testcase, khóa bộ test, chấm source ngoài và lưu bằng chứng đầy đủ cho hàng chục bài. Kết quả định lượng cho thấy khả năng bảo toàn AC và bắt WA ở mức khá, với micro TPR và TNR đều trên 86 phần trăm. Điểm còn thiếu để chuyển thành kết quả luận văn vững là tính ổn định giữa các bài, quy trình điều tra false positive, mở rộng holdout và gắn kết quả với phiên bản code có thể tái lập.

Phụ lục A Kết quả thành công gần nhất theo từng bài

Mỗi dòng là run thành công gần nhất sau khi loại batch chưa hoàn tất. TPR và TNR là oracle metric theo nhãn. Dấu gạch ngang nghĩa là không có mẫu số đánh giá được.

Bài	Nguồn	Run	Test	Vòng	Coverage	TPR	TNR	Phân loại	Giây
cf1000a	Codeforces	20261012-162125	11	2	80.0%	89.5%	85.0%	Đạt 0,8	122,9
cf1000b	Codeforces	20261012-162125	22	2	100.0%	95.0%	85.0%	Đạt 0,8	86,3
cf1003a	Codeforces	20261012-144702	21	2	100.0%	100.0%	100.0%	Mạnh	65,2
cf1003c	Codeforces	20261012-162125	21	2	100.0%	40.0%	100.0%	Cần cải thiện	90,7
cf1004a	Codeforces	20261012-162125	22	2	100.0%	95.0%	100.0%	Mạnh	92,7
cf1004c	Codeforces	20261012-162125	22	2	100.0%	80.0%	90.0%	Đạt 0,8	94,0
cf1005a	Codeforces	20261012-162125	4	2	0.0%	100.0%	30.0%	Cần cải thiện	76,0
cf1005b	Codeforces	20261012-162125	24	2	100.0%	100.0%	90.0%	Mạnh	107,8
cf1006a	Codeforces	20261012-162125	2	2	0.0%	95.0%	95.0%	Mạnh	76,4
cf1006c	Codeforces	20261012-162125	21	2	100.0%	100.0%	100.0%	Mạnh	95,8
cf1007a	Codeforces	20261012-162125	19	2	100.0%	100.0%	95.0%	Mạnh	88,3
cf1008a	Codeforces	20261012-144702	23	2	100.0%	100.0%	90.0%	Mạnh	75,8
cf1008b	Codeforces	20261012-162125	20	2	90.0%	100.0%	65.0%	Cần cải thiện	112,1
cf1009b	Codeforces	20261012-162125	23	2	100.0%	85.0%	100.0%	Đạt 0,8	88,2
cf1011a	Codeforces	20261012-162125	20	2	100.0%	90.0%	100.0%	Mạnh	80,5
cf1011b	Codeforces	20261012-162125	24	2	100.0%	100.0%	100.0%	Mạnh	100,8
cf1352c	Codeforces	20261010-144532	15	2	100.0%	95.0%	—	Chưa đo đủ	—
cf1949b	Codeforces	20261011-232837	19	2	100.0%	0.0%	100.0%	Cần cải thiện	154,0
cf2218b	Codeforces	20261010-141412	18	2	100.0%	100.0%	100.0%	Mạnh	—
cf2275d	Codeforces	20261010-090844	1	2	0.0%	100.0%	11.1%	Cần cải thiện	—

Bài	Nguồn	Run	Test	Vòng	Coverage	TPR	TNR	Phân loại	Giây
G1	Khác	20261012-141920	15	2	100.0%	100.0%	40.0%	Cần cải thiện	126,6
p02548	CodeNet	20261011-235022	21	2	100.0%	95.0%	100.0%	Mạnh	113,9
p02554	CodeNet	20261012-103819	17	2	100.0%	90.0%	100.0%	Mạnh	179,0
p02555	CodeNet	20261012-103819	20	2	100.0%	100.0%	100.0%	Mạnh	235,2
p02574	CodeNet	20261011-235022	18	2	63.6%	95.0%	85.0%	Đạt 0,8	138,5
p02580	CodeNet	20261011-235022	21	2	100.0%	80.0%	85.0%	Đạt 0,8	169,9
p02584	CodeNet	20261012-103819	23	2	100.0%	90.0%	80.0%	Đạt 0,8	216,2
p02585	CodeNet	20261012-103819	28	2	100.0%	84.2%	89.5%	Đạt 0,8	108,3
p02586	CodeNet	20261012-103819	21	2	90.9%	45.0%	85.0%	Cần cải thiện	235,5
p02596	CodeNet	20261012-103819	17	2	100.0%	95.0%	100.0%	Mạnh	183,7
p02598	CodeNet	20261012-103819	20	2	100.0%	95.0%	80.0%	Đạt 0,8	85,1
p02599	CodeNet	20261012-103819	20	2	88.9%	70.0%	90.0%	Cần cải thiện	82,1
p02614	CodeNet	20261012-103819	24	2	100.0%	95.0%	100.0%	Mạnh	82,0
p02623	CodeNet	20261012-103819	21	2	88.9%	95.0%	55.0%	Cần cải thiện	377,2
p02629	CodeNet	20261012-103819	15	2	100.0%	100.0%	95.0%	Mạnh	75,7
p02642	CodeNet	20261012-103819	23	2	100.0%	100.0%	94.7%	Mạnh	120,7
p02661	CodeNet	20261011-235022	21	2	100.0%	90.0%	75.0%	Cần cải thiện	360,3
p02678	CodeNet	20261012-103819	14	2	87.5%	94.7%	90.0%	Mạnh	460,9
p02685	CodeNet	20261011-235022	22	2	100.0%	100.0%	100.0%	Mạnh	153,3
p02691	CodeNet	20261012-103819	22	2	100.0%	85.0%	50.0%	Cần cải thiện	237,5

Bài	Nguồn	Run	Test	Vòng	Coverage	TPR	TNR	Phân loại	Giây
p02702	CodeNet	20261012-103819	21	2	100.0%	65.0%	100.0%	Cần cải thiện	187,2
p02709	CodeNet	20261011-235022	22	2	100.0%	80.0%	100.0%	Đạt 0,8	474,7
p02714	CodeNet	20261012-103819	21	2	100.0%	80.0%	94.7%	Đạt 0,8	72,1
p02720	CodeNet	20261012-103819	15	2	100.0%	95.0%	100.0%	Mạnh	91,2
p02762	CodeNet	20261012-103819	20	2	100.0%	95.0%	89.5%	Đạt 0,8	241,9
p02768	CodeNet	20261011-235022	20	2	100.0%	100.0%	100.0%	Mạnh	236,6
p02781	CodeNet	20261011-235022	24	2	100.0%	73.7%	100.0%	Cần cải thiện	214,0
p02787	CodeNet	20261012-134947	23	2	100.0%	70.0%	94.7%	Cần cải thiện	95,6
p02813	CodeNet	20261011-235022	22	2	100.0%	94.7%	95.0%	Mạnh	160,0
p02839	CodeNet	20261011-235022	17	2	100.0%	55.0%	80.0%	Cần cải thiện	360,6
p02949	CodeNet	20261011-235022	19	2	80.0%	94.7%	55.0%	Cần cải thiện	582,4
p02959	CodeNet	20261011-235022	23	2	100.0%	100.0%	80.0%	Đạt 0,8	479,7
p02986	CodeNet	20261011-235022	20	2	100.0%	94.7%	95.0%	Mạnh	255,5
p03003	CodeNet	20261011-235022	25	2	100.0%	75.0%	60.0%	Cần cải thiện	359,9
p03040	CodeNet	20261011-235022	18	2	100.0%	85.0%	100.0%	Đạt 0,8	213,2
p03044	CodeNet	20261012-103819	2	2	0.0%	100.0%	36.8%	Cần cải thiện	71,3
p03274	CodeNet	20261011-235022	23	2	100.0%	90.0%	95.0%	Mạnh	195,3
p03286	CodeNet	20261011-235022	14	2	100.0%	95.0%	100.0%	Mạnh	199,3
p03575	CodeNet	20261011-235022	16	2	100.0%	94.7%	80.0%	Đạt 0,8	165,7
p03862	CodeNet	20261011-235022	24	2	100.0%	90.0%	75.0%	Cần cải thiện	174,8

Phụ lục B Nguồn artifact quan trọng

Nhóm	Đường dẫn
Mô tả hệ thống	README.md, Architect.md, Specs.md
Orchestrator	testgen/pipeline.py
Bộ sinh LLM	testgen/ollama.py, testgen/claude.py, testgen/chatgpt.py
Judge	testgen/docker_judge.py, testgen/remote_judge.py, testgen/native_judge.py
Checker	testgen/checker.py, testgen/checkers/
Cấu hình	config/pipeline.json, config/judge.json, config/sandbox.json, config/runtimes.json
Dữ liệu	data/problems/<id>/statement.md, checker.json, oracle/manifest.json
Kết quả một run	output/.../report.json, test-suite.lock.json, iteration-*.json, executions-*.jsonl
Kết quả batch	output/batches/<timestamp>/batch-report.json và logs/
Kiểm tra checker	output/codenet-additional20-validation/report.json